접수번호	※작성하지 않음

「2025년 통계데이터 활용대회」 데이터분석 보고서

제 목	1인 가구 기반 고독사 영향 요인 분석 구조적 요인 중심 접근

신 청 자 명	소속/직위	동국대학교	성 명	정예경
	휴대전화		전자우편	
제출일	2025.07.02			

1. 배경

□ 주제 선정

1인 가구를 기반으로, 고독사 영향 요인을 구조적 요인 중심으로 접근하고자 한다.

□ 분석 필요성 및 전략

2020년 3279명, 2021년 3378명, 2022년 3559명, 2023년 3661명으로, 매년 고독사 사망자 수는 꾸준히 증가하고 있다. 특히 고독사의 주요 위험 요인 중 하나로 지목되는 1인가구 비율 역시 지속적으로 증가하고 있어, 고독사 예방을 위한 데이터 기반의 구조적 위험 요인 분석이 필요한 시점이다. 본 분석은 정책적으로 활용 가능성이 높은 구조적 지표들을 도출하는 것을 목표로 한다.

1인 가구를 중심으로 필터링한 데이터를 바탕으로, 연령, 건강보험료 분위, 거주 형태, 1인 가구 비율 등 다양한 사회경제적 변수를 지역 단위에서 종합적으로 고려하였다. Random Forest 모델과 SHAP, PDP 등의 해석 기법을 활용해 고독사 위험을 높이는 요인뿐만 아니라 위험을 완화하는 요인까지 함께 분석하였다.

2. 데이터 분석

□ 데이터 선정(사용한 데이터 및 이유 등)

- [고독사 발견 당시 거주지 현황](출처: KOSIS「고독사발생현황」, 보건복지부)
- [고독사 발생 현황: 성별·연령별](출처: KOSIS「고독사발생현황」, 보건복지부)
- [고독사 발생 현황: 지역별](출처:KOSIS「고독사발생현황」, 보건복지부)
- [고독사 사망 전 1년간 건강보험료 분위별 가입자 유형] (출처 : KOSIS「고독사발생현황」, 보건복지부)
- [성 및 거처의 종류별 1인가구-시군구](출처:KOSIS「인구총조사」, 통계청)
- [1인가구비율(시도/시/군/구)](출처:KOSIS 통계청(인구총조사과))
- [성, 연령 및 세대구성별 인구-시군구](출처:KOSIS「인구총조사」, 통계청)
- [시도별 보험료 분위별 현황, 적용인구 현황 by Province](출처: 2018, 2019, 2020, 2021 지역별 의료이용 통계(PDF), 국민건강보험공단)

⇒ 본 분석의 목적은 고독사에 영향을 미치는 요인을 지역 단위에서 파악하고, 인구 10만명당 고독사 발생 현황(명)을 효과적으로 설명하는 예측 모델을 구축하는 데 있다. 이를 위해 위 데이터셋을 활용하여 고독사 발생 요인을 사전 분석하고, 그 영향력을 검토한 뒤 주요 변수를 모델의 feature로 활용하였다.

□ 데이터 분석(분석 프로세스, 분석방법, 접근방법 등)

1. 1차 데이터 수집 및 정제

- 보건복지부의「고독사발생현황」으로부터 수집한 고독사 사망자 거주지, 성별·연령별 분포, 지역별 발생현황, 사망 전 1년간 건강보험료 분위 데이터는

연도별 변화를 직관적으로 파악할 수 있도록 연도를 컬럼으로 배치한 wide-form 구조로 구성하였다. 그리고, 그 아래행에 실질 요인을 컬럼으로 배치함으로써 시계열 비교 분석에 용이한 형태로 정제하였다. 또한 [고독사 사망 전 1년간 건강보험료 분위별 가입자 유형] 자료의 경우 각각의 분위에 해당하는 사람들의 분포를 보기 위해 미상값을 제거하고 분위별 해당 인원수를 퍼센트 형태로 바꿔서 처리하였다.

- 공개된 고독사 사망자 데이터는 광역시 단위가 전부이기 때문에, 「인구총조사」로부터 고독사 사망자의 거처유형, 성별·연령별 분포를 연도별로 광역시 단위로 정제하였다. 또한 수치가 5 미만이라 X표시된 값들은 0으로 처리하였다.

2. 데이터 시각화

- 1차 데이터 수집으로 얻은 정보로 고독사에 영향을 미치는 요인을 식별하고, 영향력을 가시화하는 것이 목적이라 따로 데이터 전처리는 수행하지 않았다. 위에서 정제한 데이터를 바탕으로 요인별 특성에 맞게 그래프로 나타내었다.

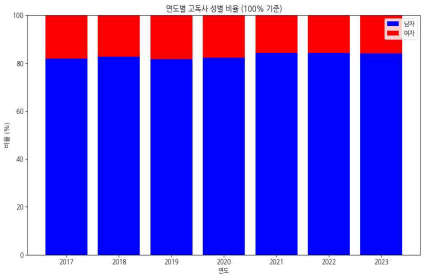

그림 1. 연도별 고독사 성별비율

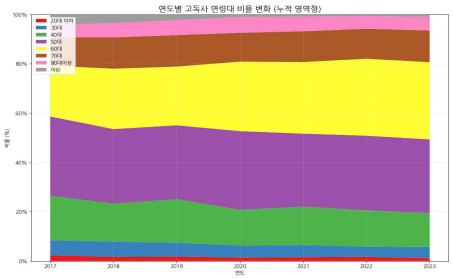

그림 2. 연도별 고독사 연령대 비율 변화(누적영역형)

그림 3. 2017,2019,2021 누적 기준 지역별 인구 10만명당 고독사 수

- 그림 1을 통해 여러해 동안 변함없이 고독사 사망자의 80%가까이가 남성이라는 사실을 알 수 있다. 그림 2를 통해서는 고독사 사망자 중 60대가 차지하는 비중이 점점 커지고 있으며, 70대 이상이 차지하는 비중이 적지 않음을 알 수 있다. 그림 3을 통해서는 지역별로 인구 10만명당 고독사 사망자 수가 뚜렷하게 차이남을 알 수 있다.

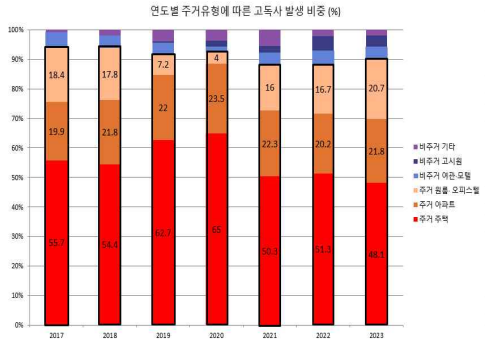

그림 4. 연도별 주거유형에 따른 고독사 발생 비중

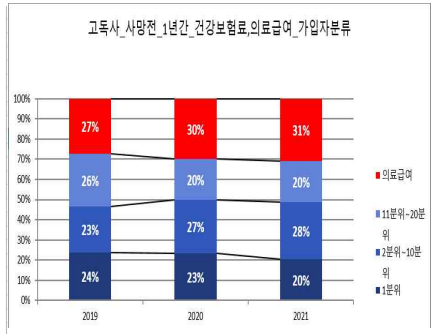

그림 5. 고독사 사망전 1년간 건강보험료,의료급여 가입자 비중

- 그림 4를 통해서는 고독사 사망자수의 70% 가까이가 주택과 아파트에서 발생한다는 사실을 알 수 있으며, 그림 5를 통해서는 고독사 사망자수 중 저소득층(1분위와 의료급여 대상자)의 비율이 절반 가까이 된다는 것을 알 수 있다.

3. 2차 데이터 수집 및 정제

- 데이터 시각화 결과를 통해 성비, 연령대, 거주 유형, 건강보험료 소득 분위를 핵심 변수로 선정하였다. 보건복지부의 「2022년 고독사 예방 실태조사 연구」에서 고독사 위험군을 산정할 때 1인가구를 바탕으로 조사한 것을 근거하여, 선정한 변수에 따른 데이터셋은 광역시별 1인가구를 기준으로 수집하였다.
  단, 건강보험료 소득분위는 1인 가구 기준 데이터의 부재로 전체 가구 기준으로 수집하였다. 또한 고독사 발생과 연관이 높은 것으로 알려진 1인 가구 비율 역시 변수로 포함하였다.
- 지역 변수의 경우 지역별 고독사 비율에 차이가 있었으나, 그 원인을 '지역 자체'가 아닌 해당 지역의 구조적 특성으로 판단하여 머신러닝 feature에서는 제외하였다. 수집한 데이터셋에서 수치가 5미만이라 X로 나타난 값은 0으로 처리하였다.

4. 고독사 영향 요인 분석을 위한 데이터셋 제작

- 2차 데이터 수집 및 정제를 통해 구축한 데이터셋에서, 앞서 진행한 데이터 시각화 결과를 바탕으로 유의미하다고 판단된 세부 변수들을 추출하여 새로운 분석용 데이터셋을 구성하였다. 선택된 세부변수들은 [**'1인가구비율', '성비', '20대이하'(29세 이하), '30대,40대', '50대,60대', '70대이상', '1분위 ~ 3분위+의료급여(%)'(저소득층), '4분위~7분위(%)', '8분위~10분위(%)', '단독주택', '아파트'**]이고, 타깃값은 '인구_십만명당_고독사_발생현황(명)'이다.
  그리고 각 컬럼 값은 특정 시도의 연도별 데이터를 기반으로 입력되었다. 연령대, 소득분위, 거처유형의 경우 해당시도 1인가구의 인구 대비 비율(%)로 정제하여, 타깃 변수와 동일하게 비례적 관점에서 분석이 이루어지도록 하였다.

5. 머신러닝을 위한 전처리

- feature간에 다중공선성이 존재할 경우 머신러닝 모델의 성능이 제대로 나오지 않고 모델의 설명력이 떨어진다. 따라서 이를 확인하기 위해 heatmap을 만들었다.

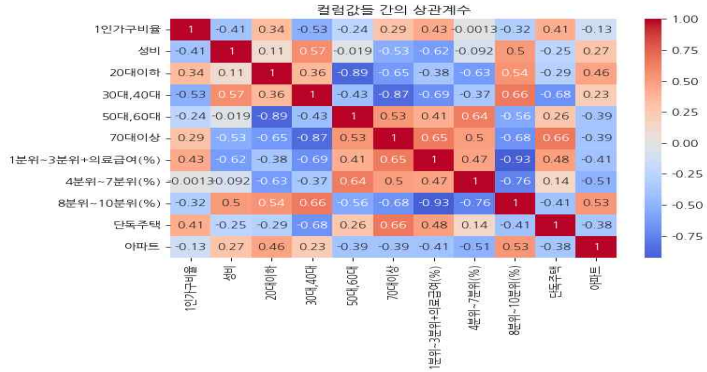

- 본 데이터셋에서 대부분의 변수는 백분율(%) 단위로 구성되어 있으나, 성비는 남성/여성*100 비율로 산출되어 상대적으로 스케일이 상이하였다. 이로 인해 성비 변수가 머신러닝 모델에 적절히 반영되지 않을 가능성이 있었고, 데이터의 양이 많지 않아 이상치의 영향을 고려할 필요도 있었다. 이에 따라 스케일의 일관성을 확보하고 이상치의 영향을 완화하기 위해 Standard Scaler를 적용하기로 결정하였다.

6. 머신러닝 모델 결정 및 하이퍼파라미터 튜닝, K 폴드 교차검증 실시

- heatmap 결과 다중공선성이 상당히 존재하는 것으로 밝혀졌다. 따라서 초기에는 다중공선성을 완화하고, 적은 데이터셋에 유리한 ElasticNet을 사용하였다. 그런데 저소득층일수록 고독사율이 높을 것이라는 기존 지식에 위배되는 결과가 도출되어 해석이 왜곡되는 문제가 있었다. 이에 변수들과 타깃 값 사이에 비선형 관계가 존재한다고 판단하여 랜덤포레스트 모델로 변경하였다.
- 이후 모델 성능 개선을 위해 다양한 feature를 적용해보고, 하이퍼 파라미터 튜닝을 하였다. 또한 모델의 신뢰도를 위해 다중공선성 정도를 평가하는 VIF, 과적합 여부를 판정하기 위한 K 폴드 교차검증을 실시하였다.

7. 모델의 결과를 Shap, 1D PDP를 통해 해석

- 테스트셋 성능과 K 폴드 교차검증의 성능이 모두 뛰어나고, VIF 결과가 양호한 모델을 선정하여 해당 모델을 Shap, 1D PDP를 통해 해석하였다.

□ 분석 결과 및 해석

```
📌 [다중공선성 확인용 VIF]
                 변수명        VIF
0                70대이상   2.882758
1  1분위~3분위+의료급여(%)   7.737762
2    1인가구비율_X_저소득층   9.292108
3      단독주택_X_50,60   7.179754
4        단독주택_X_저소득  13.920659

📌 [테스트셋 성능 평가]
✅ MSE: 0.7545
✅ R² : 0.7388

📌 [5-폴드 교차검증 R² 결과]
Fold 1: 0.8232
Fold 2: 0.6475
Fold 3: 0.7170
Fold 4: 0.6421
Fold 5: 0.5913
✅ 평균 R² (CV): 0.6842
```

(1) 과적합 위험이 적고, 성능이 우수했던 모델은 '70대 이상', '1분위~3분위+의료급여(%)', '1인 가구비율_X_저소득층', '단독주택_X_50,60대', '단독주택_X_저소득층' 항을 사용한 모델이다. 해당 모델에서는 하이퍼 파라미터를 max_depth=7, n_estimators=500, min_samples_leaf=2, max_features=5, random_state=42로 튜닝하였다. 이 모델에 대해 VIF를 계산한 결과, '단독주택_X_저소득층' 항의 VIF 수치가 상대적으로 높게 나타났으나, 다중공선성에 민감하지 않은 랜덤 포레스트 모델 특성상 해당 수준은 수용 가능한 범위로 판단된다.

본 모델의 테스트셋 기준 성능은 MSE 0.7545, R^2 0.7388로 상당히 우수한 예측력을 보였다. 또한 K=5로 설정하여 5-Fold 교차검증을 수행한 결과, 평균 R^2는 0.6842로 테스트셋 성능보다는 약간 낮지만, 여전히 전반적으로 안정적이고 뛰어난 성능을 유지하였다.

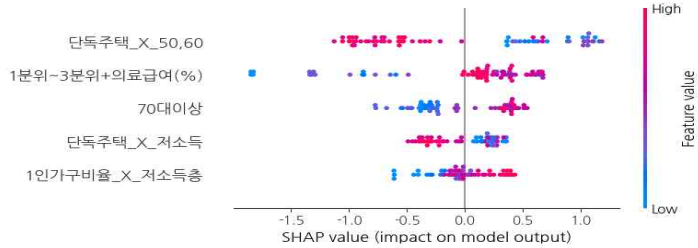

(2) SHAP value 분석 결과, 과반 이상의 변수는 사전 가설 및 상식과 부합하는 경향을 보였다. 먼저, '1분위~3분위+의료급여(%)'항의 경우, 저소득층 비율이 높을수록 고독사 발생률도 높아지는 양상이 확인되었다. '70대 이상'변수와 '1인 가구비율_X_저소득층'항 역시 각각 70대 이상 인구 비율이 높을수록, 그리고 1인가구와 저소득층이 동시에 많은 지역일수록 고독사 발생률이 증가하는 것으로 나타나, 기존 예측과 일치하는 결과를 보였다.

그러나 '단독주택_X_50,60대'항에서는 다소 이례적인 결과가 관찰되었는데, 해당값이 높을 수록 오히려 고독사 발생률이 감소하는 경향을 보였다. 마찬가지로 '단독주택_X_저소득층'항 역시, 예상과 달리 단독주택 거주 비율이 높고 저소득층 비율이 높은 지역일수록 고독사 발생률이 오히려 낮아지는 패턴을 나타냈다.

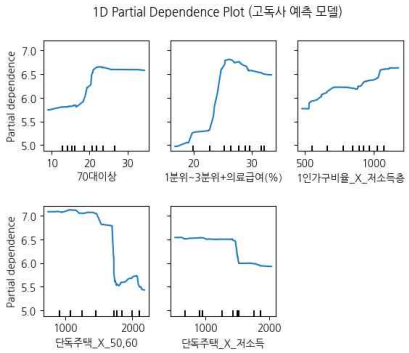

(3)고독사 발생율에 feature가 미치는 영향을 자세히 분석해보기 위해 1D PDP와 Shap 의존도 그래프를 그려 보았다. 1D PDP의 경우 이전의 Shap value 그래프와 같은 경향성을 확인할 수 있었다. 다만 feature가 특정값 이상일 때 타깃값이 급속하게 변하는 지점이 있어서, 해당 지점을 세밀하게 분석하기 위해 Shap 의존도 그래프를 확인했다.

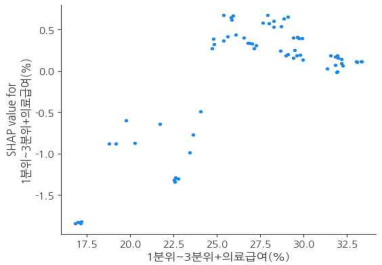

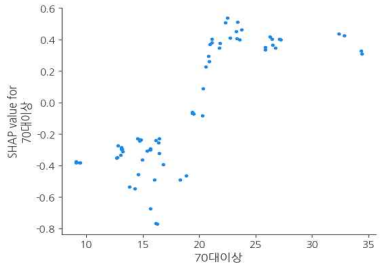

먼저 '1분위~3분위+의료급여(%)'항의 경우 저소득층의 비율이 약 25%가 될 때까지 고독사 발생율이 급격하게 증가하는 형태를 띈다. 이는 저소득층의 비율이 25% 또는 그 이상이거나, 저소득층의 비율이 25%에 근사하도록 점점 높아지고 있는 지역이라면 예방정책을 우선적으로 집중할 필요가 있음을 시사한다.

다음으로, '70대 이상' 항의 경우 지역의 70대 이상 비율이 20%가 될 때까지 고독사 발생율이 급격하게 올라가는 경향이 보인다. 이는 지역의 70대이상 인구의 비율이 20% 또는 그 이상이거나, 70대 이상 인구 비율이 20%에 근사하도록 점점 높아지고 있는 지역이라면 고독사 발생에 주의를 기울여야함을 시사한다. 특히, 고령화사회가 진행됨에 따라 70대 이상 인구비율이 점점 늘어날것으로 보여 각별한 주의가 필요하다.

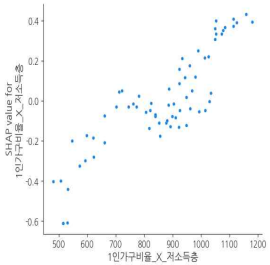

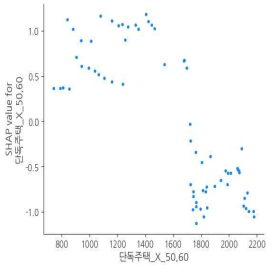

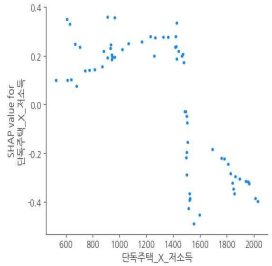

또한 1인가구비율_X_저소득층 항의 경우, 1인가구비율과 저소득층의 비율이 동시에 높은 지역일 경우 고독사 발생율이 높아짐을 알 수 있다. 한편, '단독주택_X_50, 60' 항의 경우 단독주택과 50대, 60대 인구의 비율 곱이 약 1400 이전 일때는 고독사 발생율이 증가하는 형태를 띄며, 1400 이후일때는 감소하는 형태를 보인다. 이는 고독사 사망자 중 50대와 60대의 비중이 매년 약 50%이상임을 고려할 때, 단독주택이 많이 조성된 지역일 경우 지역 내 사회적 연결망이 잘 유지되는 환경일 수 있으며, 이러한 요인이 사회적 고립을 완화시켜 고독사 사망률을 떨어뜨리는 역할을 했음을 추측할 수 있다.

'단독주택_X_저소득' 항에서도 단독주택과 저소득층의 비율의 곱이 약 1400일때를 기점으로 고독사 사망률이 급락하는 것과, 앞서 저소득층일수록 고독사 사망률이 높아짐을 감안할 때 단독주택이 많은 환경이 주거 환경이 분절적이지 않고 오히려 주민 간 유대 관계가 활발히 유지되고 있는 환경일 가능성이 있음을 시사한다.

한편, 본 연구에서는 개별 고독사자 데이터셋이 아닌, 1인가구 기준의 제한적인 데이터를 활용하여 성비 변수의 모델 내 반영이 제한적이었다. 이를 보완하고자 Standard Scaler를 적용하여 스케일을 정규화하였으나, 성비 변수를 포함한 모델은 오히려 성능이 하락하는 경향을 보여, 해당 변수가 본 모델에서는 예측을 저해하는 노이즈 요인으로 작용했음을 확인하였다.

3. 분석 활용 전략

□ 기대효과

본 분석은 **인구공학적 구조를 중심으로 한 분석 틀을 새롭게 도입**하여, 고독사 위험도를 예측하는 머신러닝 모델을 구축하였다. 기존 연구들이 고독사 사망자 개별 특성이나 단일 요인에 집중해왔다면, 본 분석은 **지역별 구조적 특성과 변수 간 상호작용을 고려한 다차원적 접근을 시도**하였다는 점에서 차별성이 있다.

현재는 광역시 단위의 데이터만 제공되어 해당 범위의 정보만을 활용할 수밖에 없었으나, 향후 시군구 및 행정동 수준의 고독사 사망률 데이터를 추가로 결합해 모델을 적용한다면, 보다 세밀한 수준에서 위험 지역을 식별하고, 지역 맞춤형 예방 전략을 수립하는 데 더욱 효과적으로 활용될 수 있을 것이다.

□ 방향제시

기존 고독사 예방정책은 소득이나 주거형태 중심 단순 타깃팅에 머물렀다. 본 분석을 통해 고독사의 원인을 보다 다각화하여 기존에 간과되었던 인구공학적 구조를 종합적으로 정책 수립에 반영해야 함을 제시한다.

참고문헌

- 한국보건사회연구원(2022). 2022년 고독사 예방 실태조사 연구